小暖 · 现在怎么样了

一份写给不看代码的人看的说明

2026 年 11 月 12 日 · 版本 3.2.0 · 所有数字均为实测

一、这是个什么东西

小暖是一个网页版的 AI 助手。打开浏览器就能用，不用下载、不用注册，也有一份 Windows 版，一个 11.7 MB 的文件，双击就能跑。

它现在主要干四件事：陪人聊天、当学习台记东西、收集用户反馈、以及在管理员允许的前提下「自己改自己」——把用户提的意见变成代码改动。

打个比方：

它像一家不用自己租门面的小店。店面开在 Cloudflare 这个「公共商场」里，整间店的全部装修加起来 585 KB——比手机里随便一张照片还小。店里没有仓库、没有服务器要养，客人来了才开机，走了就关掉。

二、现在能干什么

入口	干什么用
对话	和 AI 聊天，可以带上下文
学习台	记笔记、整理知识
更新日志	每次改了什么，都能查到
插件中心	像手机装 App 一样装新功能
设置	换模型、换语言、填自己的 Key
（藏在设置里）反馈箱	用户提意见

（藏在管理密码后）自迭代	AI 按意见改自己的代码

另外，它能说三种话：简体中文、繁體中文、English，共 235 条文案 × 3 种语言。

三、跑得怎么样，要花多少钱

三个关键数字，都是刚测的：

看什么	实际情况	换成大白话
打开一次要下多少东西	473 KB	约等于一张手机照片
整个网站多大	585 KB	一张照片多一点
装到电脑上的那个文件	11.7 MB	一首歌的大小
页面里的零件数量	467 个	算轻的，打开很快
写这个产品用的代码	约 2 万行	中等规模的小工具
请 AI 回答问题的钱	目前 0 元	在 Cloudflare 免费额度内

AI 用的是 Cloudflare 自带的 GLM-4.7-Flash 模型，用户不用自己买 Key 就能聊。如果用户愿意填自己服务商的 Key，也可以走自己的账户。

结论：按现在的使用量，一分钱不花也能跑；要扩到几千人每天用，才会开始产生费用。

四、有什么毛病（说人话版）

挑最要紧的五条，按严重程度排：

1. 钥匙一天过期三次（最烦）

每次要把新版本送上线，都得重新拿一次「门禁卡」，而且必须人工点一下同意。今天已经点了四次。这不是产品问题，是流程问题，但最影响进度。

2. 电话本里还留着一个打不通的号码

配置里写着一条备用线路，那个地址早就失效了（连域名都解析不到）。留着会让以后排查问题的人白费时间，应该删掉。

3. 门口的登记本只够一个人用

现在限制「一个人一天能提多少意见」是记在内存里的。人一多、或者服务重启，这个计数就清零了，等于限制会失效。

4. 招来的临时工没发工牌

第三方插件装上以后，权限和「店主」一样大——它想看什么、改什么都可以。现在只靠一层「只准装自己家的」在挡，长期要给它发工牌（声明需要什么权限）。

5. 有些毛病只有我肉眼发现

上一次「插件中心的门被自己关上了」「从商店装插件装不上」，这两个问题自动检查都没抓到，是我一个个点出来的。这说明体检项目还不够。

五、接下来建议怎么走

近期（这一周就能做完，成本很低）

- 换一把不会过期的钥匙，让上线不再需要人工点同意
- 删掉那条打不通的备用线路
- 把已经踩过的两个坑写进自动检查，以后同类问题自动报警
- 官方插件商店补 3–5 个真能用的插件（现在只有 1 个示例，货架是空的）

中期（一两个月）

- 给插件发工牌：装的时候声明要什么权限，跨来源的插件还要对暗号（校验指纹）
- 限流改成多人共享，不再一重启就清零
- 两套后端（云端一套、本地一套）合并成同一份规则，现在改一处要改两处
- 上线前自动用真浏览器把主要页面点一遍，不靠人眼

远期（三到六个月）

- 多模型：一个模型挂了自动换另一个，顺便控制成本上限
- 换设备能同步：现在聊天记录只存在本机浏览器里
- 做付费版：授权码 + 按用量计费 + 给企业私有部署（安装包已经有了）

不建议做的两件事

- 不建议为了「看起来像某个开源项目」去硬套它那套复杂结构，我们的东西没那么复杂，套上只会更乱
- 不建议现在就做多用户租户：现在没有登录体系，硬做会把安全问题放大十倍

六、一句话总结

东西不大、跑得动、目前不花钱。真正拖后腿的不是功能不够，而是「钥匙老过期」和「体检不到位」。把这两件补上，它就有持续做下去的地基了。

本说明由实测数据整理：仓库代码量、线上接口、浏览器实测、发布记录。技术细节见 docs/STATUS-2026-11-12.md 与 docs/REDTEAM.md。